
КАФЕДРА

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
РУКОВОДИТЕЛЬ

должность, уч. степень, звание

подпись, дата

инициалы, фамилия

Отчет о лабораторной работе №1

Знакомство с Jupyter Notebook Знакомство с Jupyter Notebook

По дисциплине: Основы машинного обучения

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ ГР. №

подпись, дата

инициалы, фамилия

Санкт-Петербург 2024

Цель работы:

Знакомство со средами Jupyter Notebook и Google Colaboratory, а также библиотеками Pandas и matplotlib.

Задание 1

Откройте Jupyter-ноутбук `jupyter_assignment.ipynb` в этом репозитории. Скопируйте путь в адресной строке браузера. Перейдите в Google Colab, в меню выберите "Файл" -> "Открыть ноутбук", в открывшемся окне слева выбрать "GitHub", затем:

- вставить в поле для поиска скопированный URL;
- поставить галочку "Показывать личные хранилища" ("Include private repos");
- и нажать на иконку с лупой. При необходимости разрешить Colab доступ к аккаунту GitHub, если откроется новое окно с таким приглашением. Среди результатов поиска выбрать `jupyter_assignment.ipynb` и приступить к выполнению задания.




Рисунок 1 – блокнот Google Colab с первой частью задания




Рисунок 2 – блокнот Google Colab с пояснениями

Задание 2

Откройте в Google Colab Jupyter-ноутбук `matplotlib_assignment.ipynb`, ознакомьтесь с его содержимым и выполните задание.





Рисунок 3 – ноутбук Google Colab для второй части задания



```
import numpy as np
from matplotlib import pyplot as plt
### BEGIN YOUR CODE
```

Student_ID = 13

```
### END YOUR CODE
```

```
task_id = None if Student_ID is None else Student_ID % 25 if Student_ID % 25 > 0 else 25
print(f"Пожалуйста, используйте математическую функции No {task_id} ниже.")
```

```
def my_function(x, a, b, c, d):
    # Вычисление y(x) по формуле  $ax^2 + by^2 = c^2$ 
    # Решаем уравнение относительно y
    return np.sqrt((c**2 - a * x**2) / b)
```

```
### BEGIN YOUR CODE
```

```
# Присваиваем значения параметрам в виде кортежей
```

```
a = 2, 3, 1
```

```
b = 1, 2, 0.5
```

```
c = 5, 6, 4
```

```
d = None
```

```
x = np.linspace(0.1, 2, 100) # Изменяем диапазон, чтобы избежать комплексных значений
```

```
### END YOUR CODE
```

```

# Создаем графики
fig, axes = plt.subplots(3, 1, figsize=(10, 15)) # Изменяем расположение на 3 строки и 1
столбец

# Строим графики для каждого набора параметров
for i in range(3):
    y = my_function(x, a[i], b[i], c[i], d)
    axes[i].plot(x, y, label=f'$a={a[i]}, b={b[i]}, c={c[i]}$', linestyle='--', linewidth=2,
marker='o')
    axes[i].set_title(f'$a={a[i]}, b={b[i]}, c={c[i]}$', fontsize=14)
    axes[i].set_xlabel('$x$', fontsize=12)
    axes[i].set_ylabel('$y(x)$', fontsize=12)
    axes[i].grid(True, linestyle=':', color='gray')
    axes[i].legend()

# Общий заголовок
fig.suptitle('Графики функции $y(x) = \sqrt{\frac{c^2 - a \cdot x^2}{b}}$ при разных
параметрах', fontsize=16)

# Отображение графиков
plt.tight_layout()
plt.show()

```

Задание 3

В этом задании необходимо научиться базовым приемам работы с данными. Необходимо загрузить заданный по варианту датасет, провести разведочный анализ данных, сформулировать гипотезы о возможном значении всех полей в датасете, проверить эти гипотезы, и ответить на вопросы по данным.

Цель. Знакомство с разведочным анализом данных и применение Pandas для извлечения информации

```
#### BEGIN YOUR CODE
```

```
Student_ID = 13
```

```
#### END YOUR CODE
```

```

datasets =
[('Chipotle', 'https://raw.githubusercontent.com/justmarkham/DAT8/master/data/chipotle.tsv'),
('US Air Carrier market in
2019', 'https://raw.githubusercontent.com/markpolyak/datasets/refs/heads/main/data/aircarrier_
market_us_2019.zip'), ('Open Food Facts',
'https://raw.githubusercontent.com/markpolyak/datasets/refs/heads/main/data/en.openfoodfact
s.org.products.tsv.tar.bz2')]

```

```

dataset_id = None if Student_ID is None else Student_ID % 3
if dataset_id is None:

```

```

    print("ОШИБКА! Не указан порядковый номер студента в списке группы.")
else:
    print(f'Датасет '{datasets[dataset_id][0]}' доступен по следующей ссылке:
    {datasets[dataset_id][1]}")
    print(f'В заданиях ниже, где нужно выбрать вопрос, всегда выбирайте вопрос №
    {dataset_id+1}')

### BEGIN YOUR CODE

# Скачиваем файл
!wget
https://raw.githubusercontent.com/markpolyak/datasets/refs/heads/main/data/aircarrier_market_us_2019.zip

# Распаковываем содержимое ZIP-архива
!unzip aircarrier_market_us_2019.zip
# !tar ...
# !gunzip ...

### END YOUR CODE

import pandas as pd

# Загружаем CSV-файл в DataFrame
df = pd.read_csv('aircarrier_market_us_2019.csv')

# Приводим названия столбцов к нижнему регистру
df.columns = df.columns.str.lower()

# Выводим названия столбцов для проверки
print(df.columns)

# Получаем список столбцов
columns = df.columns.tolist()

# Выводим список столбцов
print(columns)

# Считаем количество уникальных значений в столбце 'carrier'
answer1 = df['carrier'].nunique()

# Выводим ответ, Количество авиаперевозчиков
print(answer1)

# Фильтруем данные для маршрутов из Великобритании (GB) в США (US)
uk_us_flights = df[(df['origin_country'] == 'GB') & (df['dest_country'] == 'US')]

# Суммируем пассажиров, груз и почту
total_passengers = uk_us_flights['passengers'].sum()
total_freight = uk_us_flights['freight'].sum()
total_mail = uk_us_flights['mail'].sum()

```

```

# Выбираем максимальное из трех значений
answer2 = max(total_passengers, total_freight, total_mail)

print(answer2)

# Создаем новый столбец с общим грузом (mail + freight)
df['total_cargo'] = df['mail'] + df['freight']

# Группируем данные по уникальному перевозчику и суммируем общий груз
cargo_per_carrier = df.groupby('unique_carrier_name')['total_cargo'].sum()

# Находим авиаперевозчика с максимальным значением груза
answer3 = cargo_per_carrier.idxmax()

print(answer3)

# Фильтруем данные для авиакомпаний, которые осуществляют рейсы из США
us_passengers = df[df['origin_country'] == 'US']

# Группируем данные по уникальному перевозчику и суммируем количество пассажиров
passengers_per_carrier = us_passengers.groupby('unique_carrier_name')['passengers'].sum()

# Находим максимальное количество пассажиров
answer4 = passengers_per_carrier.max()

print(answer4)

# Группируем данные по парам городов (origin и destination) и суммируем количество пассажиров
passengers_between_cities = df.groupby(['origin', 'dest'])['passengers'].sum()

# Находим пару городов с максимальным количеством пассажиров
max_passengers = passengers_between_cities.idxmax() # Пара городов
max_passengers_count = passengers_between_cities.max() # Максимальное количество пассажиров

# Сохраняем ответ в виде списка
answer5 = [max_passengers[0], max_passengers[1]]

print(answer5)

# Фильтруем данные по городам LAX и JFK
filtered_data = df[(df['origin'].isin(['LAX', 'JFK'])) & (df['dest'].isin(['LAX', 'JFK']))]

# Группируем по авиакомпаниям и суммируем количество пассажиров
passengers_by_carrier = filtered_data.groupby('unique_carrier_name')['passengers'].sum()

# Находим общее количество пассажиров между этими городами
total_passengers = passengers_by_carrier.sum()

```

```

# Находим 3 авиакомпании с наибольшим количеством перевезенных пассажиров
top_carriers = passengers_by_carrier.nlargest(3)

# Вычисляем процент от общего пассажиропотока для каждой авиакомпании
percentage = (top_carriers / total_passengers) * 100

# Округляем до двух знаков после запятой
answer6 = percentage.round(2).tolist()

print(answer6)

# Фильтруем данные по классу F
class_f_data = df[df['class'] == 'F']

# Группируем данные по стране назначения и суммируем количество пассажиров
passengers_by_country = class_f_data.groupby('dest_country_name')['passengers'].sum()

# Находим общий пассажиропоток из США
total_passengers_us = class_f_data['passengers'].sum()

# Вычисляем процент международного пассажиропотока для каждой страны
percentage_by_country = (passengers_by_country / total_passengers_us) * 100

# Находим страну с третьим по величине пассажиропотоком
answer7 = percentage_by_country.nlargest(3).index[2] # Индекс 2 соответствует третьему
по величине

print(answer7)

# Фильтруем данные по городам из answer5
filtered_data = df[(df['origin'].isin(answer5)) & (df['dest'].isin(answer5))]

# Группируем данные по месяцу и суммируем количество пассажиров
monthly_passengers = filtered_data.groupby('month')['passengers'].sum()

# Находим месяц с максимальным пассажиропотоком
answer8 = monthly_passengers.idxmax() # Возвращает месяц с максимальным
пассажиропотоком

print(answer8)

import matplotlib.pyplot as plt

# Группируем данные по городам и авиакомпаниям, суммируя количество пассажиров
passenger_flow = df.groupby(['origin', 'unique_carrier_name'])['passengers'].sum().unstack()


# Построение стековой столбчатой гистограммы
passenger_flow.plot(kind='bar', stacked=True, figsize=(20, 8)) # Увеличиваем размер
графика

```



```
# Настройка графика
plt.title('Стековая столбчатая гистограмма пассажиропотока по авиакомпаниям в городах')
plt.xlabel('Города')
plt.ylabel('Количество пассажиров')
plt.xticks(rotation=45)
plt.legend(title='Авиакомпании', bbox_to_anchor=(1.05, 1), loc='upper left')

# Показать график
plt.show()
```



Вывод:

В ходе выполнения заданий в средах Jupyter Notebook и Google Colaboratory, а также при работе с библиотеками Pandas и Matplotlib, я приобрел полезные навыки в анализе и визуализации данных. Изучение данных в ноутбуках и использование графических инструментов значительно упростили процесс работы с информацией и позволили более наглядно представлять результаты анализа.